

Edge Impulse 完整 Pipeline 體驗報告

2026-09-01 • 執行者：JR Chen • 平台：Edge Impulse Studio (web, 免費 Developer Plan) • 任務：keyword spotting (聽懂「hello world」) • 全程零 code、零硬體

TL;DR：用官方開源音訊資料集，在 Edge Impulse 免費網頁版走完「上傳→DSP→訓練→測試→手機即時推論→匯出」完整 TinyML pipeline，約 90 分鐘。驗證集準確率 **90.8%** (**int8 量化後**)。最終產出一個 **52KB 的 C++ 模型** + 零依賴推論套件，可直接編進任何 MCU 韌體；手機瀏覽器本地即時推論驗證成功（斷網可跑）。



☑ 掃碼試玩這個模型（免帳號、免安裝）

手機掃描 → 瀏覽器開啟後允許麥克風 → 對手機說「hello world」。模型以 WebAssembly 在你手機的瀏覽器本地執行，不回傳雲端——開飛航模式照樣能跑，這就是 edge inference。

連結：[smartphone.edgeimpulse.com/classifier.html?](https://smartphone.edgeimpulse.com/classifier.html?publicProjectId=523486)

`publicProjectId=523486`

完整公開專案（資料、模型、pipeline 皆可檢視與 clone）：

studio.edgeimpulse.com/public/523486/latest

§1 Pipeline 總覽與各階段 I/O



階段 (Studio 頁面)	輸入 (I)	輸出 (O)	人做的事
Data acquisition	keyword-spotting/ (248MB, 含 info.labels)	已標註資料庫：44m31s 音訊， Train/Test 80/20	選資料夾、按上傳
Create impulse	—	pipeline 定義：1000ms 視窗、 500ms stride → MFCC → Classifier	三個下拉選單
MFCC (Generate features)	每視窗 16,000 個採樣點	650 維特徵 × 3,595 視窗 + 特徵散 點圖 + DSP 硬體成本估計	用預設參數、按兩顆鈕
Classifier	特徵視窗 (helloworld 2,446 / noise 577 / unknown 572)	int8 模型：val acc 90.8%、loss 0.25 + 各 MCU latency/RAM/Flash 估計	預設超參數、按 Start training (約 5 分)
Model testing	290 筆從未參與訓練的樣本	hold-out 混淆矩陣與各類別 F1	按 Classify all
Deployment (手機)	QR code	手機瀏覽器本地即時推論 (WASM+int8, 斷網可跑， continuous 模式)	掃碼、給麥克風權 限
Deployment (C++)	選 int8+EON Compiler、按 Build	5.8MB zip：零依賴 C++ 推論套件	一顆鈕

§2 訓練結果 (validation set, int8 量化版)

實際 \ 預測	helloworld	noise	unknown
helloworld	94.9%	3.7%	1.4%
noise	19.8%	72.9%	7.3%
unknown	8.0%	4.5%	87.5%
F1	0.95	0.74	0.88

- 整體 accuracy **90.8%**、AUC 0.97、加權 F1 0.91——demo 等級健康。
- 已知弱點：**noise → helloworld 誤判 19.8%**。成因是視窗切割後類別失衡 4:1:1 (helloworld 原始檔多為 10 秒長，被 1s 視窗切出 2,446 份；另兩類皆 1 秒檔)。手機實測可重現：環境噪音偶爾誤觸發。
- int8 量化 vs float32 精度差 <1%——量化幾乎白吃。

§3 硬體成本估計 (Cortex-M4F 80MHz，訓練頁直接給)

項目	時間	RAM	備註
DSP (MFCC)	154 ms/視窗	峰值 15 KB	確定性計算，非 NN
NN 推論 (int8+EON)	數十 ms 級	KB 級	模型本體 52KB Flash

這是 Edge Impulse 與一般 MLOps 最大的差異點：訓練當下就知道模型塞不塞得進目標 MCU，不用等部署才發現爆 RAM。

§4 最終拿到的東西 (deliverables)

```
cjr96-project-1-cpp-mcu-v2-impulse-#1/ ← Deployment 一鍵匯出的 zip (5.8MB)
├─ edge-impulse-sdk/      28MB 源碼：MFCC 等 DSP 實作、TFLite-Micro 推論核心、
│                          CMSIS (ARM 加速數學庫)、各平台移植層。編譯後僅留用到的部分
├─ tflite-model/         52KB：模型本體。EON Compiler 已把模型「編譯成 C++ 源碼」
│                          (權重=C 陣列、結構=寫死的函式)，無 .tflite、無解譯器 → 省 RAM/Flash
└─ model-parameters/     24KB：膠水設定 (1000ms 視窗、16kHz、MFCC 參數、3 個 label)
```

使用方式：`#include "ei_run_classifier.h"` → 餵 16,000 個 float → `run_classifier()`
→ 回傳三類機率。整合者完全不需要懂 ML。最終韌體約 100–200KB。

- 另可從 Dashboard 直接下載裸模型檔：`.tflite` (int8 / float32)、TensorFlow SavedModel——接回自家 Python 流程用。
- 其他一鍵匯出目標：Arduino library、WebAssembly、Linux .eim、Docker 推論 server、官方支援板的整包韌體 bin。

§5 「燒錄」是怎麼一回事 + 入門硬體

模型已被編譯成 C++，所以「燒模型」＝一般韌體燒錄：`main.c` (讀麥克風→`run_classifier`→行動) + SDK 用 `arm-none-eabi-gcc` 交叉編譯成 `firmware.bin`，USB 寫入 MCU Flash (新板多為 UF2：按住 BOOT 插 USB，把檔案拖進跳出的隨身碟即完成)。上電即跑，無網路、無 OS。

板子	約略價格	適合	備註
Seeed XIAO ESP32-S3 Sense	NT\$500–700	聲音+影像 (FOMO) 都能玩	拇指大，帶麥克風+相機，CP 值首選
Arduino Nano 33 BLE Sense	NT\$1,200–1,500	本專案直接燒	官方全支援+pre-built firmware，教學最多
Raspberry Pi Pico (RP2040)	NT\$150–250	學 UF2 燒錄流程	需外接 I2S 麥克風 (約 NT\$50)
Seeed Wio Terminal	NT\$1,100	帶螢幕的展示 demo	官方全支援

§6 平台評估結論

免費額度 (Developer Plan，2025 起為預設免費層)

- 3 個私有專案、公開專案無限、每專案 3 協作者
- 單一 job 上限 60 分鐘 / 16GB RAM (本案訓練約 5 分鐘，綽綽有餘)
- 每專案 10 個 experiments
- 內部部署 $\leq 1,000$ 台；**禁止對第三方出貨** (商用需 Enterprise)

與一般 MLOps 的本質差異

- 一般 MLOps 管「模型的生命週期」；Edge Impulse 管「**模型變成裝置韌體的生產線**」
- DSP 前處理是 pipeline 一級公民，會與模型一起編進 C++ 輸出
- 訓練時即顯示目標 MCU 的 latency/RAM/Flash
- 哲學與主流 end-to-end 相反：**手工 DSP 特徵扛掉大部分工作，讓 NN 小到 KB 級**——這就是 TinyML 的本質
- 弱項：實驗管理陽春、不適合大模型與開放場景

主要來源：edgeimpulse.com/pricing • docs.edgeimpulse.com (getting-started、pre-built datasets、deployment) • 本專案公開頁 studio.edgeimpulse.com/public/523486/latest